

# Wstęp

Obliczenia z wykorzystaniem komputerów są nieodłączną częścią współczesnej nauki. Natomiast, podstawa obliczeń komputerowych sa obliczenia równoległe. Gdy korzystamy z 1 komputera, nawet bardzo mocnego, jesteśmy ograniczeni do około 32 procesorów (obecnie) i kilkuset Gb pamięci RAM. Co wiecej, czas obliczeń spada (przynajmniej tego byśmy sobie życzyli) jak 1/(liczba procesów). Dlatego z reguły potrzebujemy i chcemy wykorzystać ich jak najwięcej.

# Obliczenia równoległe

Każdy program przygotowany do pracy równoległej oprócz podstawowego algorytmu, potrzebuje mechanizmu komunikacji. W naszym przypadku będzie to standard MPI czyli Message Passing Interface. Biblioteka OpenMPI dostarcza nam narzedzi niezbednych do uruchamiania i komunikacji miedzy poszczególnymi procesami składajacymi się na nasz "program".

#### Ćwiczenie 1

Przygotuj plik program.cpp o poniższej treści. Następnie skompiluj go za pomoca programu mpic++:

```
#include <stdio.h>
#include <mpi.h>
#include <unistd.h>
int main(int argc, char *argv[]) {
  int numprocs, rank, namelen;
  char processor name[MPI MAX PROCESSOR NAME];
  MPI Init(&argc, &argv);
   MPI Comm size(MPI COMM WORLD, &numprocs);
   MPI Comm rank(MPI COMM WORLD, &rank);
   MPI_Get_processor_name(processor_name, &namelen);
    printf("Hello World! from process %d out of %d on %s\n",
          rank, numprocs, processor_name);
  MPI_Finalize();
```

Powyższy program można skompilować i uruchomić używajac komend:

```
mpic++ -o program program.cpp
mpirun -np 4 program
```

gdzie 4 to liczba procesorów, na których ma zostać uruchomiony program.

Przeanalizujmy teraz program. Funkcje MPI Init i MPI Finalize służą do odpowiednio inicjalizacji i zakonczenia komunikacji pomiedzy procesami. Powinny one być odpowiednio na poczatku i na końcu programu, ponieważ tylko pomiedzy nimi można wykonać jakiekolwiek wywołanie biblioteki MPI i komunikować się z innymi procesami w grupie. Wywołanie MPI Comm size zwroci nam liczbe procesów (np. 4), zaś MPI Comm rank zwróci nam numer naszego procesu (np. 0,1,2 lub 3). Zmienna rank jest wiec jedną z najważniejszych w kodzie, ponieważ odróżna nasze procesy. Jeśli jej nigdzie nie użyjemy, to wszystkie nasze procesy zrobia dokładnie to samo.

## Ćwiczenie 2

Rozszerz program tak, by każdy proces losował pewne liczby i wypisywał pewne statystyki:

- 1. Zaalokuj tablice liczb rzeczywistych a o rozmiarze n = 10000 \* (rank + 1)
- 2. Wypełnij ja liczbami losowymi z przedziału [0,1]
- 3. Wypisz komunikat o wylosowaniu i wypisz pierwszą liczbę a[0]
- 4. Oblicz  $S_1 = \sum_i a_i$

- 5. Wyświetl średnią:  $\mu = \frac{1}{n}S_1$ 6. Oblicz  $S_2 = \sum_i (a_i \mu)^2$ 7. Wyświetl wariancję:  $\sigma^2 = \frac{1}{n-1}S_2$

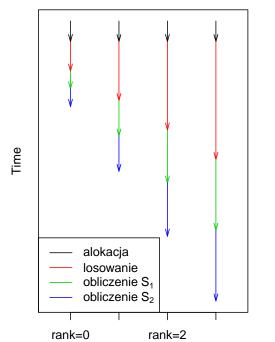
Pamietaj aby we wszystkich komunikatach umieszczać zmienna rank, tak by było wiadomo, który komunikat pochodzi, od którego procesu. By mieć pewność, że komunikaty wypisywane są rzeczywiście wtedy, kiedy występują w kodzie (a nie sa buforowane przez system), dodaj komende fflush(stdout); zaraz po każdym wywołaniu printf. Intrukcja ta powoduje, że cały buforowany tekst zostanie wyświetlony na ekran od razu.

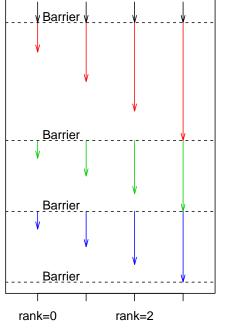
Aktualnie, losowanie jest bardzo niedoskonałe. Wszystkie procesy wylosowały ten sam ciąg losowy (można zobaczyć to już po pierwszym elemencie, który jest identyczny we wszystkich procesach. Żeby tego uniknać przekaż np. wartość time(NULL) +rank jako ziarnodo funkcji  ${\tt srand},$ tak aby ciąg losowy był zainicjalizowany inną liczbą na każdym procesorze.

## Ćwiczenie 3

3

Zaobserwuj, że różne procesy dochodzą do różnych etapów algorytmu w różnych momentach. Np. średnia dla procesu 0 może być wyznaczona przed wypełnieniem liczbami tablicy w procesie 1. Możemy wymusić aby procesy czekały na siebie nawzajem dodając instrukcję MPI\_Barrier(MPI\_COMM\_WORLD); po wywołaniach printf/fflush. Bariera w programach wielowątkowych powoduje, że wszystkie procesy czekają w tym miejscu kodu, aż reszta procesów dojdzie do tego miejsca, a następnie wszystkie razem ruszają dalej. Zauważ, że powoduje to iż program działa tak wolno, jak jego najwolniejszy element. Przebieg programu we wszystkich procesach jest pokazany poglądowo na poniższym obrazku:





### Ćwiczenie 4

Użyj funkcji wykonującej redukcję aby obliczyć średnią globalną (po wszystkich procesach) i wariancję z a. Redukcja w programowaniu równoległym polega na wykonaniu jakiejś operacji, np. sumowania czy wzięcia maxiumum, na danych ze wszystkich procesów. W bibliotece MPI mamy do dyspozycji funkcję:

- source to wskaźnik do danych, które mamy np. zsumować.
- destination to wskaźnik do miejsca, gdzie ma być umieszczony wynik.
- count to liczba elementów danych do zsumowania. Czyli np. 1 jeśli dane to jedna liczba.
- datatype to typ danych, które sumujemy: MPI\_INT lub MPI\_DOUBLE.
- operation to operacja, którą wykonujemy, np: MPI\_SUM lub MPI\_MAX.
- root to numer procesu, do którego przesyłamy wynik, np: 0.
- Ostatni argument to uchwyt komunikatora, na którym ma zostać wykonana redukcja. W naszym wypadku to domyślny komunikator MPI\_COMM\_WORLD

Użyj tej funkcji aby obliczyć globalne statystyki, a następnie wyświetl je (pamietaj, że mają one sens tylko na węźle root). Weź pod uwagę, że globalne n jest inne niż n lokalne.

Bliźniaczą do funkcji MPI\_Reduce jest funkcja MPI\_Allreduce. Przesyła ona wynik do wszystkich procesów, a nie tylko do procesu root.

## Ćwiczenie \*

Stwórz nowy program równoległy program2.cpp, który będzie obliczał powyższą średnią i wariancję, używając tylko jednej pętli, bez alokowania tablicy a (tzn., będzie liczył średnią i wariancję bez przechowywania pojedyńczych elementów). By to zrobić przekształć wzór na wariancję:

$$\sigma^2 = \frac{1}{n-1} \sum_i \left( a_i - \frac{1}{n} \sum_j a_j \right)^2$$

tak aby był wyrażony za pomocą  $S_1$  i nowego  $\hat{S}_2 = \sum_i a_i^2$ , który da się obliczyć bez znajomości średniej  $\mu$ . Użyj we wszystkich procesach tego samego (bardzo wysokiego) n. Porównaj czas wykonania wykonując:

```
time mpirun -np 1 program2
time mpirun -np 2 program2
time mpirun -np 4 program2
```

# Kolejka PBS

W przypadku każdego dużego systemu komputerowego potrzebny jest jakiś mechanizm zarządzania zasobami: 2 osoby nie mogą naraz korzystać z tego samego procesora/rdzenia. W prawdziwym systemie komputer centralny służy do zlecania zadań, pozostałe, tzw. węzły obliczeniowe, przyjmują i wykonują zadania. Na info3 jest tylko jeden węzeł który spełnia obie role.

#### Ćwiczenia

Sprawdź co zrobi komenda qsub -I (wielka litera i). To program do wysyłania zadań do wykonania. Opcja -I oznacza tryb interaktywny: zostaniemy zalogowani na wolny węzeł przez ssh. Wpisz teraz qstat, sprawdź opcje -n i -f. Zobacz, że twoje 'zadanie' jest uruchomione w kolejce. Wyloguj się teraz, bo blokujesz zasoby kolejki. Jednocześnie mogą być wykorzystywane tylko 4 rdzenie. Ilością pobieranych zasobów można sterować poprzez flagę -1, np.:

```
qsub -l nodes=1:ppn=4 -I
qsub -l nodes=1:ppn=2 -l walltime=00:00:10 -I
```

Parametr walltime=00:00:10 mówi nam o maksymalnym czasie trwania zadania. Po upłynięciu tego czasu zadanie zostanie automatycznie przerwane.

## Zadania nieinteraktywne

W większości przypadków czas trwania zadania interaktywnego jest mocno ograniczony. Bardziej użyteczne są zadania nieinteraktywne. Aby zlecić takie zadanie potrzebny jest nam plik zadania plik.sh:

```
#!/bin/bash
cd $PBS_0_WORKDIR
mpirun --hostfile $PBS_NODEFILE --display-map ./program
```

Zlecamy jego wykonanie przez

```
qsub plik.sh
```

Obejrzyj zawartość katalogu, znajdź pliki o rozszerzeniu .oXX i .eXX. Czym one są? Dodaj do skryptu plik.sh komendę sleep 8, która spowoduje ze zadanie *zaśnie* na 8 sekund, tak by w liście wypisywanej przez qstat dało się je zobaczyć. Jako grupa możecie dodać wiele takich zadań i zobaczyć jak są po kolei realizowane przez kolejkę PBS.

## Ćwiczenie

Spróbuj wykonać któryś z wcześniejszych skryptów konwerujących obrazki (np konwersje .jpg na .gif) jako nieinteraktywne zadanie w kolejce.